

2次元掛け算layer

ヒューマンインタフェース研究室
助教

はやし ひであき
早志 英朗




KYUSHU
UNIVERSITY

2018/6/1

Trainable Multiplication Layer

- 目的
 - 入力画像の局所自己相関を抽出（特に前半層）
 - 入力画像内の共起性を検出（特に後半層）

- 構造



計算の詳細

- 式変形

$$\prod_i^I x_i^{w_i} = \exp \left([\log x_1, \dots, \log x_I] \begin{bmatrix} w_1 \\ \vdots \\ w_I \end{bmatrix} \right)$$

- 学習と制約

$$\text{minimize } J = - \sum_{m=1}^M \sum_{k=1}^K T_k^{(m)} \log O_k^{(m)} + \lambda \|\mathbf{w}\|_1$$

$$\text{s.t. } \sum_{i=1}^I w_i = C_1, \quad 0 \leq w_i \leq C_2$$

$T_c^{(m)}$: Teacher vector

$O_c^{(m)}$: Network output

K : # of classes

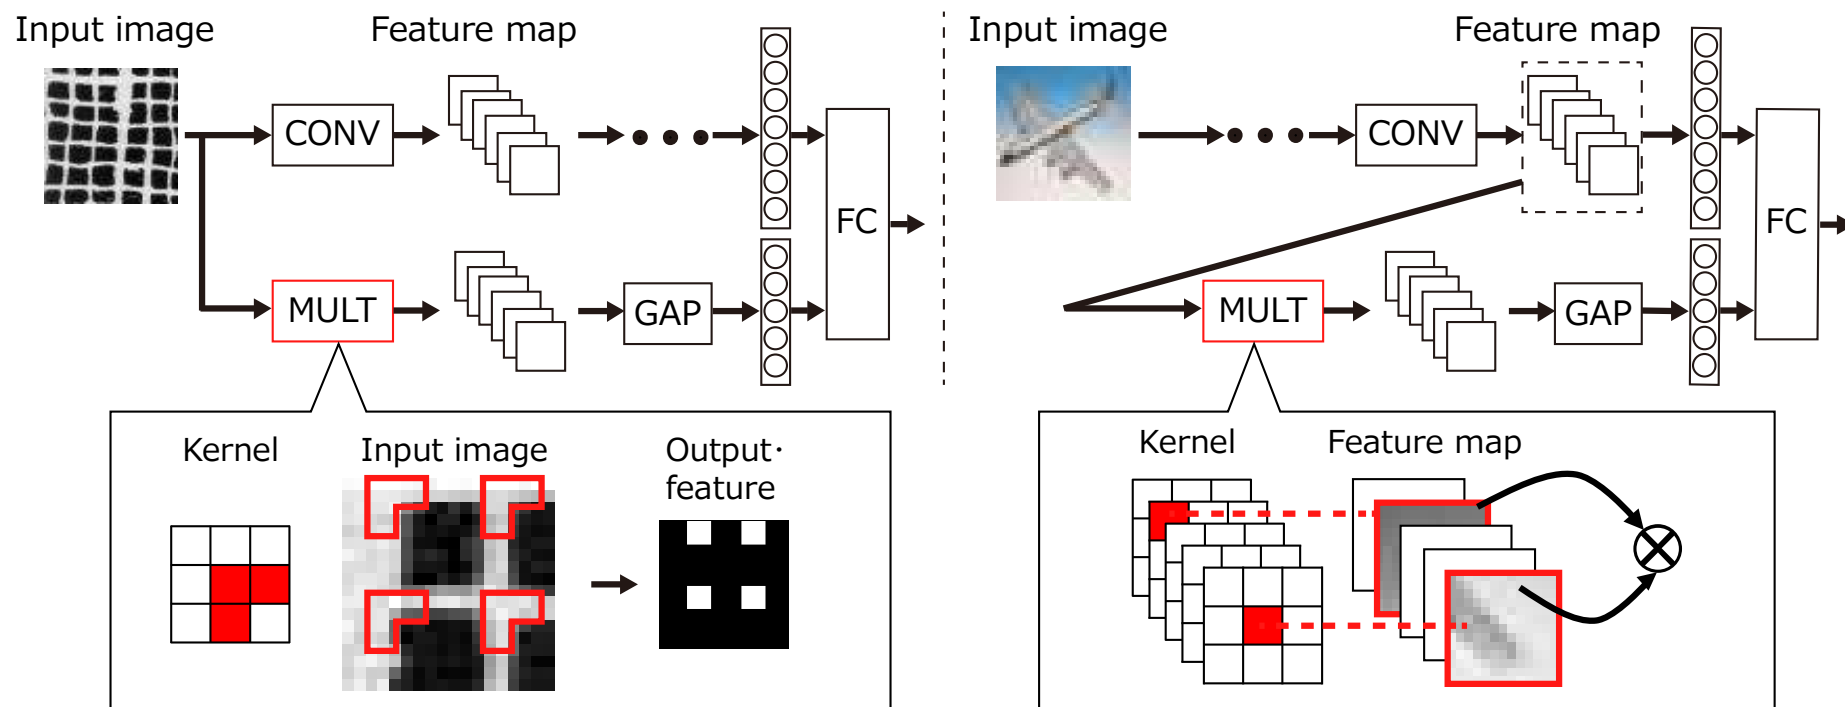
M : # of training samples

λ, C_1, C_2 : Constants

- 第1の制約は発散を抑えるために必須
- 第2の制約をつけると非零のマスクの数がおおよそ C_1/C_2 個になる

2種類の使い方

MULT: Multiplication layer, GAP: Global average pooling, CONV: Convolutional layer, FC: Fully connected layer



(a) Use as a discriminative higher-order local auto-correlation extractor


(b) Use as a co-occurrence extractor

実験

- レイヤーの特性検証
 - 超パラメータ (c_1, c_2 , カーネルサイズ) と学習されるカーネルの関係
 - Discriminative HLAC extractorとして使った場合の特性
 - Co-occurrence extractorとして使った場合の特性
- 識別実験
 - Dataset: MNIST, Brodatz, CIFAR10
 - 識別手法：
 - Shallower: LeNet (5層), LeNet + HLAC, LeNet + Proposed (DHLAC, Co-occurrence)
 - Deeper: Deep CNN (11層), Deep CNN + HLAC, Deep CNN + Proposed (DHLAC, Co-occurrence)


第2制約のパラメータと非零要素

- $C_1 = 1.0, C_2 = 0.5$




第2制約のパラメータと非零要素

- $C_1 = 1.0, C_2 = 0.33$




マスクサイズ5 x 5

- Weights




-
- Features




Filterと対応するresponse (size: 7x7)

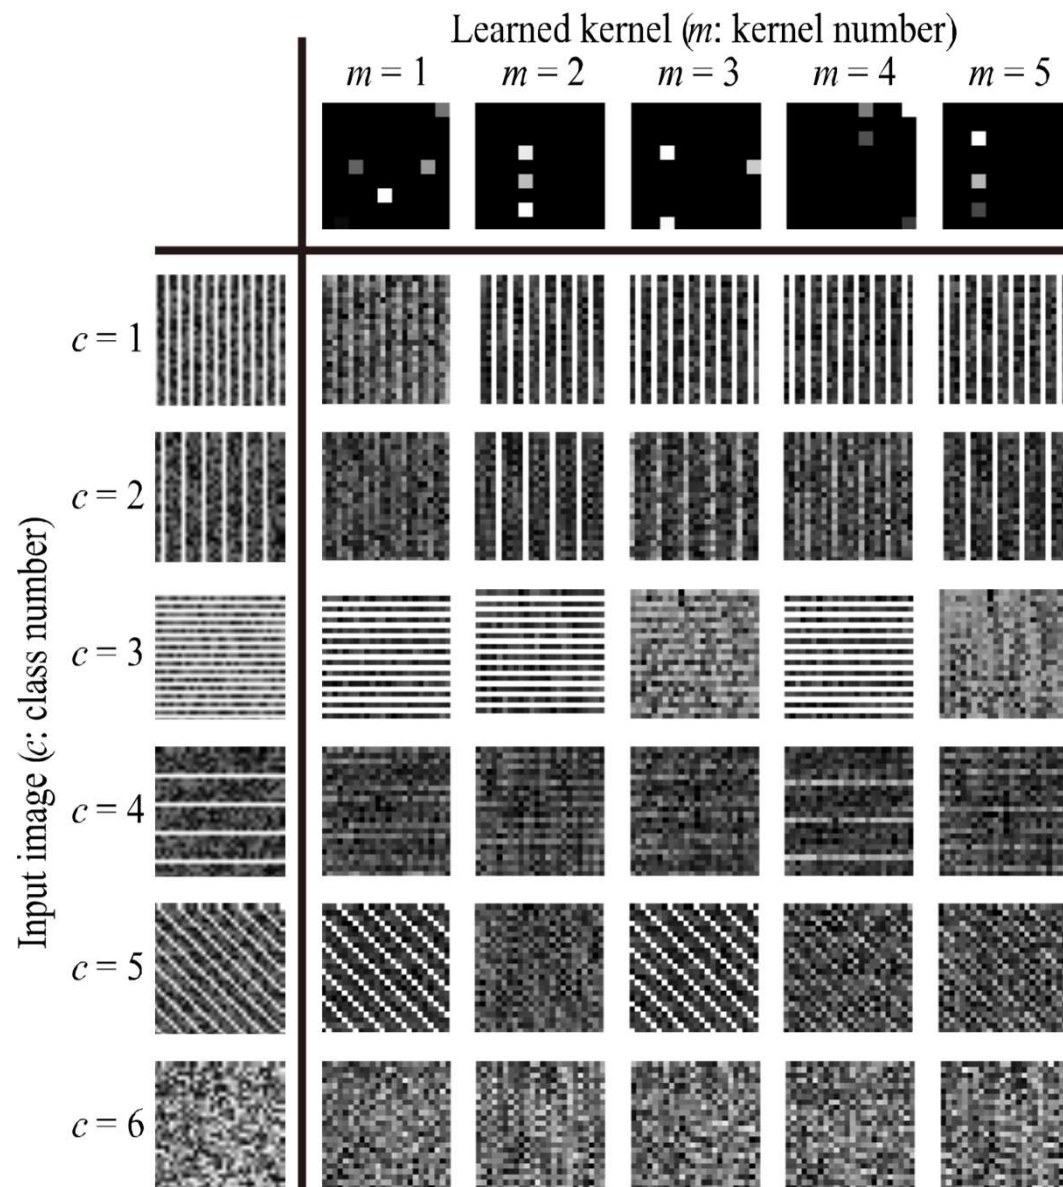
- Weights




-
- Features



Discriminative HLACとしての特性



Co-occurrence extractorとしての特性




識別実験


Table. 1 Comparison of the recognition rates (%).

	MNIST	Brodatz	CIFAR10
LeNet	99.22	74.77	74.28
LeNet + HLAC	99.15	75.96	74.81
LeNet + proposed layer (DHLAC)	99.20	76.28	73.48
LeNet + proposed layer (Co-occurrence)	99.09	77.26	77.40
Deep CNN	99.27	91.69	81.43
Deep CNN + HLAC	99.31	91.33	82.23
Deep CNN + proposed layer (DHLAC)	99.39	92.51	81.50
Deep CNN + proposed layer (Co-occurrence)	99.27	91.56	81.49


MNIST



Brodatz



CIFAR10



時系列識別に向けて

ヒューマンインタフェース研究室
助教

はやし ひであき
早志 英朗



KYUSHU
UNIVERSITY


2018/6/1

1次元でやるとどうなるか

- 時系列波形の自己相関＝周波数を抽出してほしい
 - 離散時系列の自己相関関数



$$R(\tau) = \sum_t x[t]x[t - \tau]$$

- 共起性レイヤの1次元版を実装し以下のNNを構築





時系列識別実験

- 実験データ
 - 2クラスの正弦波



- 周波数のみクラスごとで異なる
 - クラス1 : 10 [Hz], クラス2 : 14 [Hz]
- そのほかは統一
 - 時系列長 : 1.0 [s], サンプルングレート : 50 [Hz]
 - 位相は各サンプルでランダムに変更
- 学習データ数 : 20000, テストデータ数 : 2000
- 認識率は99.8%

学習されたフィルタ

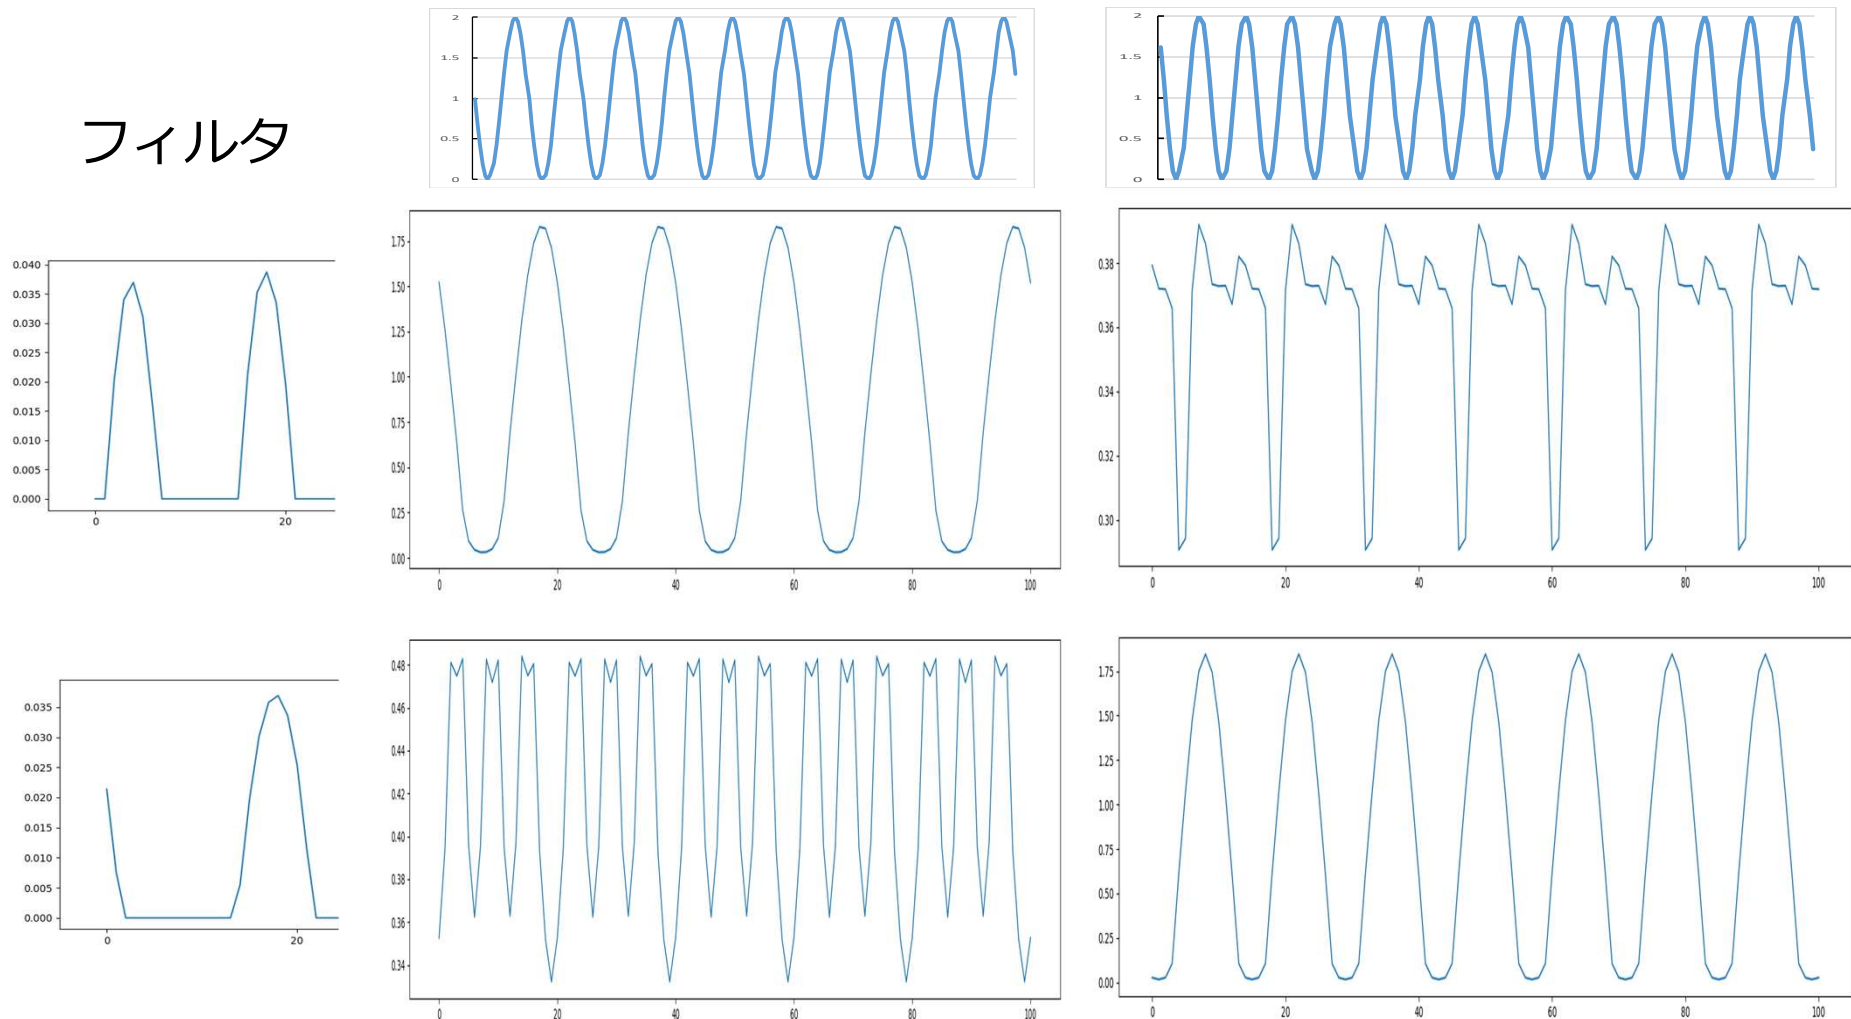


フィルタと対応する特徴量

クラス1の入力

クラス2の入力

フィルタ



全結合層直前の全サンプル平均

- 自己相関係数に相当する役割
 - 離散時系列の自己相関関数

$$R(\tau) = \sum_t x[t]x[t - \tau]$$

